

sns_addiction_regression

September 10, 2026

1 Abstract

본 연구는 학생들의 SNS 사용 관련 행동·심리 요인이 자기보고식 중독 점수와 어떤 통계적 연관성을 갖는지 분석한다. SNS 일일 사용 시간, 수면 시간, 정신 건강 점수, SNS 관련 갈등 경험, 나이를 설명 변수로 하여 OLS 회귀, 다중공선성(VIF) 진단, 잔차·영향관측치 진단, 이분산에 강건한(HC3) 추론, 순서형 로지스틱·로버스트 회귀를 통한 민감도 분석, 그리고 하위집단 조절효과 분석(상호작용 모형 및 설명변수 기반 잠재프로파일)을 수행하였다.

분석 결과, 이 데이터에서 정신 건강 점수(음의 방향)와 SNS 갈등 경험(양의 방향)이 중독 점수와 가장 강하게 연관되며, 수면 시간은 음의 연관성을 보인다. 이 관계는 강건 표준오차, 순서형 로지스틱, 로버스트 회귀, 영향관측치 제거 등 모든 대안적 추정에서 부호와 유의성이 일관되게 유지된다.

데이터에 관한 주의. 본 분석에 사용한 자료는 Kaggle에 공개된 합성(*synthetic*) 데이터셋 (“Students’ Social Media Addiction”)이다. 종속 변수가 설명 변수들의 거의 결정론적 함수이며 (704개 관측치의 설명변수 조합이 모두 유일한 중독 점수에 대응), 상관계수와 결정계수($R^2 \approx 0.95$)가 실제 행동과학 조사에서 관측되기 어려운 수준이다. 따라서 아래의 모든 결과는 이 데이터셋의 생성 구조에 대한 기술(記述)이며, 실제 학생 모집단에 대한 인과적·일반화 가능한 주장이 아니다. 본 보고서는 이 제약 하에서 회귀·진단·하위집단 분석 파이프라인을 방법론적으로 올바르게 수행하는 방법을 함께 보이는 것을 목적으로 한다.

2 Introduction

2.1 Research Question

“이 데이터셋에서 학생들의 일일 소셜미디어 사용 시간, 수면 시간, 정신건강 점수, 소셜미디어 관련 갈등 경험은 소셜미디어 중독 점수와 어떤 방향·크기의 통계적 연관성을 갖는가? 그 연관성은 하위집단에 따라 달라지는가?”

2.2 Hypotheses

전역 가설(“변수 하나라도 유의”) 대신, 이론에 근거한 방향성 가설을 사용한다. (compensatory internet use / displacement 가설 등)

가설	내용	예상 부호
H1	정신 건강 점수가 낮을수록 중독 점수가 높다	$\beta(\text{Mental_Health}) < 0$
H2	SNS 관련 갈등 경험이 많을수록 중독 점수가 높다	$\beta(\text{Conflicts}) > 0$
H3	수면 시간이 짧을수록 중독 점수가 높다	$\beta(\text{Sleep}) < 0$
H4	일일 사용 시간이 길수록 중독 점수가 높다 (다른 변수 통제 시)	$\beta(\text{Usage}) > 0$
H5	위 연관의 크기는 “SNS가 학업에 영향을 준다”고 인식하는지 여부에 따라 다르다	상호작용 $\neq 0$

2.3 분석상의 개념적 유의점 (순환성)

Conflicts_Over_Social_Media, Avg_Daily_Usage_Hours, Affects_Academic_Performance는 “SNS가 삶에 미치는 부정적 영향”이라는 중독 구성개념과 상당 부분 겹친다. 따라서 이들을 넣은 모형의 높은 설명력은 “예측”이라기보다 구성개념 내부의 동어반복에 가깝다. 본 보고서는 개념적으로 비교적 독립적인 변수(수면, 나이, 인구통계)와 구성개념 중첩 변수를 구분하여 해석한다.

3 Setup

```
[1]: from pathlib import Path

import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

import statsmodels.api as sm
import statsmodels.formula.api as smf
from statsmodels.stats.outliers_influence import variance_inflation_factor
from statsmodels.stats.diagnostic import (
    het_breuschpagan,
    het_white,
    linear_reset,
)
from statsmodels.stats.stattools import jarque_bera, durbin_watson
from statsmodels.graphics.gofplots import qqplot
from statsmodels.miscmodels.ordinal_model import OrderedModel

from sklearn.model_selection import KFold
from sklearn.mixture import GaussianMixture
from sklearn.preprocessing import StandardScaler
```

```

from scipy import stats

%matplotlib inline

SEED = 42
rng = np.random.default_rng(SEED)
pd.set_option("display.width", 120)
pd.set_option("display.max_columns", 40)

DATA_PATH = Path("data") / "Students Social Media Addiction.csv"

```

3.0.1 Helper functions

```

[2]: def compute_vif(exog: pd.DataFrame) -> pd.DataFrame:
    """예측 변수에 대한 VIF. 절편 열이 있으면 제외하고 계산한다."""
    X = exog.copy()
    drop = [c for c in X.columns if c.lower() in {"intercept", "const"}]
    X = X.drop(columns=drop)
    X = sm.add_constant(X, has_constant="add") # VIF 계산에는 상수항이 필요
    rows = []
    for i, name in enumerate(X.columns):
        if name == "const":
            continue
        rows.append((name, variance_inflation_factor(X.values, i)))
    return pd.DataFrame(rows, columns=["Variable", "VIF"]).sort_values("VIF",
↪ascending=False)

def standardized_betas(y_name, x_names, data):
    """모든 수치형 변수를 z-표준화한 뒤 OLS를 적합해 표준화 계수( $\beta$ )를 반환."""
    cols = [y_name] + list(x_names)
    z = data[cols].apply(lambda s: (s - s.mean()) / s.std(ddof=1))
    res = smf.ols(f"{y_name} ~ " + " + ".join(x_names), data=z).fit()
    return res.params.drop("Intercept").rename("std_beta")

def cv_scores(formula, data, k=10, seed=SEED):
    """k-겹 교차검증 RMSE /  $R^2$  (표본 밖 성능)."""
    kf = KFold(n_splits=k, shuffle=True, random_state=seed)
    y_true, y_pred = [], []
    for tr, te in kf.split(data):
        fit = smf.ols(formula, data=data.iloc[tr]).fit()
        p = fit.predict(data.iloc[te])
        y_true.append(data.iloc[te][formula.split("~")[0].strip()].to_numpy())
        y_pred.append(p.to_numpy())

```

```

y_true = np.concatenate(y_true)
y_pred = np.concatenate(y_pred)
rmse = float(np.sqrt(np.mean((y_true - y_pred) ** 2)))
ss_res = np.sum((y_true - y_pred) ** 2)
ss_tot = np.sum((y_true - y_true.mean()) ** 2)
return {"cv_rmse": rmse, "cv_r2": float(1 - ss_res / ss_tot)}

def bh_adjust(pvals):
    """Benjamini-Hochberg FDR 보정 p-value."""
    p = np.asarray(pvals, dtype=float)
    n = len(p)
    order = np.argsort(p)
    ranked = np.empty(n)
    cummin = 1.0
    for rank, idx in enumerate(reversed(order), start=1):
        i = n - rank + 1
        val = p[idx] * n / i
        cummin = min(cummin, val)
        ranked[idx] = cummin
    return np.clip(ranked, 0, 1)

```

4 Data

- 출처: Kaggle, “Students’ Social Media Addiction” (합성 데이터셋)
- 원 관측치 수: 705 → 완전 중복 1행 제거 후 **704**
- 종속 변수: Addicted_Score (2-9의 유계 순서형 정수 척도, 검증된 심리척도 아님)
- 설명 변수: Avg_Daily_Usage_Hours, Sleep_Hours_Per_Night, Mental_Health_Score, Conflicts_Over_Social_Media, Age, 그리고 범주형 (Gender, Academic_Level, Most_Used_Platform, Affects_Academic_Performance, Relationship_Status, Country)

```

[3]: raw = pd.read_csv(DATA_PATH)
print("원본 shape:", raw.shape)

feature_cols = [c for c in raw.columns if c != "Student_ID"]
dupe_mask = raw.duplicated(subset=feature_cols, keep="first")
print("완전 중복 행 수:", int(dupe_mask.sum()))
print(raw.loc[raw.duplicated(subset=feature_cols, keep=False), feature_cols].
      ↪head())

df = raw.loc[~dupe_mask].reset_index(drop=True).copy()
print("\n분석용 shape:", df.shape)

```

원본 shape: (705, 13)

완전 중복 행 수: 1

Age Gender Academic_Level Country Avg_Daily_Usage_Hours Most_Used_Platform

Affects_Academic_Performance \						
241	21	Male	Graduate	Italy	5.4	Instagram
Yes						
273	21	Male	Graduate	Italy	5.4	Instagram
Yes						

	Sleep_Hours_Per_Night	Mental_Health_Score	Relationship_Status
Conflicts_Over_Social_Media	Addicted_Score		
241		6.7	5
3	7		Single
273		6.7	5
3	7		Single

분석용 shape: (704, 13)

[4]: df.info()

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 704 entries, 0 to 703
Data columns (total 13 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Student_ID                           704 non-null    int64
1   Age                                   704 non-null    int64
2   Gender                               704 non-null    object
3   Academic_Level                       704 non-null    object
4   Country                              704 non-null    object
5   Avg_Daily_Usage_Hours                704 non-null    float64
6   Most_Used_Platform                   704 non-null    object
7   Affects_Academic_Performance         704 non-null    object
8   Sleep_Hours_Per_Night                704 non-null    float64
9   Mental_Health_Score                  704 non-null    int64
10  Relationship_Status                   704 non-null    object
11  Conflicts_Over_Social_Media           704 non-null    int64
12  Addicted_Score                       704 non-null    int64
dtypes: float64(2), int64(5), object(6)
memory usage: 71.6+ KB
```

[5]: NUMERIC = ["Age", "Avg_Daily_Usage_Hours", "Sleep_Hours_Per_Night",
"Mental_Health_Score", "Conflicts_Over_Social_Media"]
df[NUMERIC + ["Addicted_Score"]].describe().T

	count	mean	std	min	25%	50%	75%
max							
Age	704.0	20.659091	1.400153	18.0	19.0	21.0	22.0
24.0							
Avg_Daily_Usage_Hours	704.0	4.918040	1.258157	1.5	4.1	4.8	5.8
8.5							

Sleep_Hours_Per_Night	704.0	6.869176	1.127631	3.8	6.0	6.9	7.7
9.6							
Mental_Health_Score	704.0	6.228693	1.104871	4.0	5.0	6.0	7.0
9.0							
Conflicts_Over_Social_Media	704.0	2.849432	0.958632	0.0	2.0	3.0	4.0
5.0							
Addicted_Score	704.0	6.436080	1.588151	2.0	5.0	7.0	8.0
9.0							

Addicted_Score는 2-9 범위의 정수 8개 값만 취하는 유계 순서형 변수다. OLS는 이를 연속으로 근사하므로 예측값이 범위를 벗어날 수 있다. 이 근사의 타당성은 뒤에서 순서형 로지스틱 회귀와 비교하여 점검한다.

Country는 704행에 110개 수준을 가지며 대부분 관측치가 1-2개다. 고정효과 더미로 넣으면 거의 포화(saturated) 모형이 되어 계수·VIF가 폭증하므로, 본 분석의 주 모형에서는 Country를 제외한다(아래 VIF 절 참조).

```
[6]: print("Country 수준 수:", df["Country"].nunique())
print(df["Country"].value_counts().tail(8))
for c in ["Gender", "Academic_Level", "Most_Used_Platform",
          "Affects_Academic_Performance", "Relationship_Status"]:
    print(f"\n{c}: {sorted(df[c].unique())}")
```

```
Country 수준 수: 110
Country
Iraq      1
Lebanon   1
Jordan    1
Oman      1
Afghanistan 1
Syria     1
Yemen     1
Bhutan    1
Name: count, dtype: int64
```

```
Gender: ['Female', 'Male']
```

```
Academic_Level: ['Graduate', 'High School', 'Undergraduate']
```

```
Most_Used_Platform: ['Facebook', 'Instagram', 'KakaoTalk', 'LINE', 'LinkedIn',
'Snapchat', 'TikTok', 'Twitter', 'VKontakte', 'WeChat', 'WhatsApp', 'YouTube']
```

```
Affects_Academic_Performance: ['No', 'Yes']
```

```
Relationship_Status: ['Complicated', 'In Relationship', 'Single']
```

4.1 Correlation Analysis

종속 변수가 순서형이므로 Pearson과 함께 **Spearman** 상관을 보고한다.

```
[7]: pearson = df[NUMERIC + ["Addicted_Score"]].corr(method="pearson")
      spearman = df[NUMERIC + ["Addicted_Score"]].corr(method="spearman")

      print("Pearson\n", pearson.round(3), "\n")
      print("Spearman\n", spearman.round(3))
```

Pearson

	Age	Avg_Daily_Usage_Hours	
Sleep_Hours_Per_Night	Mental_Health_Score \		
Age	1.000	-0.114	0.125
0.161			
Avg_Daily_Usage_Hours	-0.114	1.000	-0.791
-0.801			
Sleep_Hours_Per_Night	0.125	-0.791	1.000
0.708			
Mental_Health_Score	0.161	-0.801	0.708
1.000			
Conflicts_Over_Social_Media	-0.185	0.805	-0.677
-0.894			
Addicted_Score	-0.167	0.832	-0.765
-0.945			

	Conflicts_Over_Social_Media	Addicted_Score
Age	-0.185	-0.167
Avg_Daily_Usage_Hours	0.805	0.832
Sleep_Hours_Per_Night	-0.677	-0.765
Mental_Health_Score	-0.894	-0.945
Conflicts_Over_Social_Media	1.000	0.934
Addicted_Score	0.934	1.000


Spearman

	Age	Avg_Daily_Usage_Hours	
Sleep_Hours_Per_Night	Mental_Health_Score \		
Age	1.000	-0.103	0.132
0.158			
Avg_Daily_Usage_Hours	-0.103	1.000	-0.814
-0.802			
Sleep_Hours_Per_Night	0.132	-0.814	1.000
0.734			
Mental_Health_Score	0.158	-0.802	0.734
1.000			
Conflicts_Over_Social_Media	-0.178	0.803	-0.722
-0.909			
Addicted_Score	-0.171	0.838	-0.788

-0.950

	Conflicts_Over_Social_Media	Addicted_Score
Age	-0.178	-0.171
Avg_Daily_Usage_Hours	0.803	0.838
Sleep_Hours_Per_Night	-0.722	-0.788
Mental_Health_Score	-0.909	-0.950
Conflicts_Over_Social_Media	1.000	0.951
Addicted_Score	0.951	1.000

```
[8]: fig, axes = plt.subplots(1, 2, figsize=(13, 5))
for ax, mat, title in zip(axes, [pearson, spearman], ["Pearson", "Spearman"]):
    im = ax.imshow(mat, vmin=-1, vmax=1, cmap="RdBu_r")
    ax.set_xticks(range(len(mat.columns)))
    ax.set_xticklabels(mat.columns, rotation=45, ha="right")
    ax.set_yticks(range(len(mat.columns)))
    ax.set_yticklabels(mat.columns)
    for i in range(len(mat)):
        for j in range(len(mat)):
            ax.text(j, i, f"{mat.iloc[i, j]:.2f}", ha="center", va="center",
                    ↪fontsize=8)
    ax.set_title(f"{title} correlation")
    fig.colorbar(im, ax=ax, fraction=0.046)
plt.tight_layout()
plt.show()
```



Addicted_Score와 Mental_Health_Score(≈ -0.95), Conflicts_Over_Social_Media($\approx +0.93$)의 상관관계는 극단적으로 크다. 실제 조사 자료에서는 보기 어려운 값으로, 합성 데이터의 생성 규칙을 반영한다. 이 사실은 이후 모든 결정계수·유의확률 해석의 배경으로 유지한다.

4.2 OLS Regression — 모델 구성

모든 모형은 **HC3** 이분산-강건 표준오차로 추론한다(Covariance Type: HC3). 범주형 변수는 patsy `C()` 로 처리하여 더미 함정(dummy trap)을 피한다.

```
[9]: model1_formula = ("Addicted_Score ~ Age + Avg_Daily_Usage_Hours +
    ↳Sleep_Hours_Per_Night + "
        "Mental_Health_Score + Conflicts_Over_Social_Media")

# 모델 2: 범주형 포함 (Country 제외 - 아래 VIF 절에서 근거 제시)
model2_formula = (model1_formula
    + " + C(Gender) + C(Academic_Level) + C(Most_Used_Platform)"
    + " + C(Affects_Academic_Performance) +
    ↳C(Relationship_Status)")

model1 = smf.ols(model1_formula, data=df).fit(cov_type="HC3")
model2 = smf.ols(model2_formula, data=df).fit(cov_type="HC3")

print(model1.summary())
```

OLS Regression Results

```
=====
Dep. Variable:          Addicted_Score      R-squared:                0.945
Model:                  OLS                 Adj. R-squared:           0.944
Method:                 Least Squares       F-statistic:             2138.
Date:                   Thu, 10 Sep 2026    Prob (F-statistic):      0.00
Time:                   16:04:59            Log-Likelihood:         -305.72
No. Observations:      704                 AIC:                    623.4
Df Residuals:          698                 BIC:                    650.8
Df Model:               5
Covariance Type:       HC3
=====
```

```
=====
                                coef      std err          z      P>|z|
-----
[0.025      0.975]
-----
Intercept                10.0045      0.432      23.172      0.000
9.158      10.851
Age                      0.0038      0.010       0.378      0.705
-0.016      0.024
Avg_Daily_Usage_Hours    0.0204      0.022       0.929      0.353
-0.023      0.063
Sleep_Hours_Per_Night   -0.2098      0.020     -10.725      0.000
-0.248     -0.171
Mental_Health_Score     -0.6743      0.032     -20.973      0.000
-0.737     -0.611
Conflicts_Over_Social_Media 0.6642      0.042     15.940      0.000
```

0.583 0.746

```
=====
Omnibus:                30.933    Durbin-Watson:                2.050
Prob(Omnibus):           0.000    Jarque-Bera (JB):           41.689
Skew:                    0.404    Prob(JB):                   8.86e-10
Kurtosis:                3.877    Cond. No.                   658.
=====
```

Notes:

[1] Standard Errors are heteroscedasticity robust (HC3)

```
[10]: print(model2.summary())
```

```

                        OLS Regression Results
=====
Dep. Variable:          Addicted_Score    R-squared:                0.969
Model:                  OLS               Adj. R-squared:           0.968
Method:                 Least Squares     F-statistic:             1704.
Date:                  Thu, 10 Sep 2026   Prob (F-statistic):       0.00
Time:                  16:04:59           Log-Likelihood:          -103.74
No. Observations:      704               AIC:                    253.5
Df Residuals:          681               BIC:                    358.3
Df Model:              22
Covariance Type:       HC3
=====
=====

```

			coef	std err	z
P> z	[0.025	0.975]			

Intercept			9.8473	0.506	19.453
0.000	8.855	10.839			
C(Gender) [T.Male]			-0.0715	0.030	-2.399
0.016	-0.130	-0.013			
C(Academic_Level) [T.High School]			-0.1766	0.113	-1.562
0.118	-0.398	0.045			
C(Academic_Level) [T.Undergraduate]			-0.1889	0.050	-3.741
0.000	-0.288	-0.090			
C(Most_Used_Platform) [T.Instagram]			-0.0301	0.035	-0.870
0.384	-0.098	0.038			
C(Most_Used_Platform) [T.KakaoTalk]			-0.8587	0.054	-16.008
0.000	-0.964	-0.754			
C(Most_Used_Platform) [T.LINE]			-0.8951	0.058	-15.538
0.000	-1.008	-0.782			
C(Most_Used_Platform) [T.Linkedin]			-0.0387	0.084	-0.460
0.646	-0.204	0.126			
C(Most_Used_Platform) [T.Snapchat]			0.0813	0.171	0.475
0.635	-0.254	0.416			

C(Most_Used_Platform) [T.TikTok]	0.1436	0.036	3.965
0.000 0.073 0.215			
C(Most_Used_Platform) [T.Twitter]	-0.2014	0.047	-4.253
0.000 -0.294 -0.109			
C(Most_Used_Platform) [T.VKontakte]	-0.0374	0.049	-0.766
0.444 -0.133 0.058			
C(Most_Used_Platform) [T.WeChat]	-0.0779	0.046	-1.679
0.093 -0.169 0.013			
C(Most_Used_Platform) [T.WhatsApp]	-0.2616	0.045	-5.754
0.000 -0.351 -0.173			
C(Most_Used_Platform) [T.YouTube]	0.4833	0.200	2.415
0.016 0.091 0.875			
C(Affects_Academic_Performance) [T.Yes]	0.7509	0.055	13.565
0.000 0.642 0.859			
C(Relationship_Status) [T.In Relationship]	-0.0551	0.086	-0.639
0.523 -0.224 0.114			
C(Relationship_Status) [T.Single]	-0.1550	0.086	-1.795
0.073 -0.324 0.014			
Age	-0.0577	0.015	-3.776
0.000 -0.088 -0.028			
Avg_Daily_Usage_Hours	0.1641	0.027	6.072
0.000 0.111 0.217			
Sleep_Hours_Per_Night	-0.1033	0.024	-4.366
0.000 -0.150 -0.057			
Mental_Health_Score	-0.5671	0.029	-19.637
0.000 -0.624 -0.511			
Conflicts_Over_Social_Media	0.3550	0.043	8.248
0.000 0.271 0.439			
=====			
Omnibus:	66.662	Durbin-Watson:	2.114
Prob(Omnibus):	0.000	Jarque-Bera (JB):	152.172
Skew:	0.535	Prob(JB):	9.04e-34
Kurtosis:	5.010	Cond. No.	1.04e+03
=====			

Notes:

[1] Standard Errors are heteroscedasticity robust (HC3)

[2] The condition number is large, 1.04e+03. This might indicate that there are strong multicollinearity or other numerical problems.

관찰

- 모델 1에서 Age($p \approx 0.7$)와 Avg_Daily_Usage_Hours($p \approx 0.4$)는 다른 변수 통제 시 유의하지 않다. Avg_Daily_Usage_Hours의 단순 상관은 +0.83으로 크지만, Sleep·Mental_Health·Conflicts와 강하게 얽혀 있어 부분효과가 사라진다. → H4는 이 데이터에서 지지되지 않는다.
- 모델 2의 범주형 항은 대부분 개별적으로 유의하지 않으며(아래), 조정 결정계수 증가분에 비해 파라미터 수가 급증한다.

4.2.1 표준화 계수(β) — 효과 크기 비교

“어떤 요인의 영향이 가장 큰가”는 변수 스케일이 서로 다르므로(정신건강 4-9, 갈등 0-5, 수면 3.8-9.6) 원계수가 아니라 표준화 계수로 비교해야 한다.

```
[11]: std_b = standardized_betas("Addicted_Score", NUMERIC, df)
std_b.abs().sort_values(ascending=False).to_frame("|std_beta|").join(std_b.
↳to_frame("std_beta"))
```

```
[11]:
```

	std_beta	std_beta
Mental_Health_Score	0.469097	-0.469097
Conflicts_Over_Social_Media	0.400933	0.400933
Sleep_Hours_Per_Night	0.148937	-0.148937
Avg_Daily_Usage_Hours	0.016158	0.016158
Age	0.003391	0.003391

4.3 VIF 진단 (절편 제외, 예측변수 기준)

```
[12]: X1 = df[NUMERIC]
print("모델 1 VIF")
print(compute_vif(X1).to_string(index=False))
```

```
모델 1 VIF
```

Variable	VIF
Mental_Health_Score	5.681350
Conflicts_Over_Social_Media	5.668544
Avg_Daily_Usage_Hours	4.291639
Sleep_Hours_Per_Night	2.791006
Age	1.040677

```
[13]: # 모델 2 설계행렬(범주형 더미 포함, patsy가 기준범주 자동 제거)
X2 = smf.ols(model2_formula, data=df).fit().model.exog
X2 = pd.DataFrame(X2, columns=smf.ols(model2_formula, data=df).fit().model.
↳exog_names)
vif2 = compute_vif(X2)
print("모델 2 VIF ≥ 5 인 항")
print(vif2[vif2["VIF"] >= 5].to_string(index=False))
```

```
모델 2 VIF ≥ 5 인 항
```

Variable	VIF
Conflicts_Over_Social_Media	8.073790
C(Relationship_Status)[T.In Relationship]	7.455263
C(Relationship_Status)[T.Single]	7.405310
Avg_Daily_Usage_Hours	6.731017
Mental_Health_Score	6.579929
C(Academic_Level)[T.Undergraduate]	5.212175
C(Affects_Academic_Performance)[T.Yes]	5.118818

- **모델 1:** 모든 VIF < 6. Avg_Daily_Usage_Hours의 VIF는 약 4로 임계값(10) 미만이다. 즉 이 변수를 최종 모형에서 제외하는 근거는 다중공선성이 아니라 통계적 비유의다.
- **모델 2:** 범주형 더미, Country는 관측치가 희소한 수준이 많아 사실상 식별이 불안정하므로 주 모형에서 제외한다. 국가 효과가 관심사라면 지역 단위로 묶거나 혼합효과(랜덤절편) 모형을 써야 한다.

4.4 최종(간명) 모형 선택

후보 모형을 조정 R^2 , AIC, BIC, 10-겹 교차검증 RMSE/ R^2 로 비교한다.

```
[14]: candidates = {
    "M_full_numeric": model1_formula,
    "M_parsimonious": "Addicted_Score ~ Sleep_Hours_Per_Night +
↪Mental_Health_Score + Conflicts_Over_Social_Media",
    "M_plus_usage": "Addicted_Score ~ Sleep_Hours_Per_Night +
↪Mental_Health_Score + Conflicts_Over_Social_Media + Avg_Daily_Usage_Hours",
    "M_with_categ": model2_formula,
}

rows = []
for name, f in candidates.items():
    ols = smf.ols(f, data=df).fit()
    cv = cv_scores(f, df)
    rows.append({
        "model": name, "k_params": int(ols.df_model + 1),
        "adj_R2": ols.rsquared_adj, "AIC": ols.aic, "BIC": ols.bic,
        **cv,
    })
model_cmp = pd.DataFrame(rows).set_index("model").round(4)
model_cmp
```

```
[14]:
```

	k_params	adj_R2	AIC	BIC	cv_rmse	cv_r2
model						
M_full_numeric	6	0.9442	623.4435	650.7841	0.3759	0.9439
M_parsimonious	4	0.9443	620.4081	638.6352	0.3757	0.9440
M_plus_usage	5	0.9443	621.5838	644.3677	0.3756	0.9440
M_with_categ	23	0.9678	253.4817	358.2876	0.2898	0.9667

M_parsimonious(수면 + 정신건강 + 갈등)는 M_full_numeric 대비 BIC가 더 낮고 교차검증 성능이 사실상 동일하다(Age·Usage는 부분효과가 없어 표본 밖 성능에 기여하지 않는다). 범주형을 추가한 M_with_categ는 교차검증 RMSE가 더 낮아(0.38 → 0.29) 적합은 개선되지만, 이는 주로 일부 플랫폼 더미(KakaoTalk·LINE 등, 이 합성 데이터의 생성 규칙이 만든 신호)에서 오며 파라미터가 23개로 늘고 다중공선성도 커진다. 관심 가설의 변수는 M_parsimonious가 모두 담고 있으므로 이를 주 모형으로 삼고, 범주형을 추가해도 핵심 계수가 흔들리지 않는지 별도로 확인한다(아래 “핵심 계수 안정성” 표).

```
[15]: final_formula = "Addicted_Score ~ Sleep_Hours_Per_Night + Mental_Health_Score + Conflicts_Over_Social_Media"
final_ols = smf.ols(final_formula, data=df).fit() # 고전 SE
final_hc3 = smf.ols(final_formula, data=df).fit(cov_type="HC3") # 강건 SE
print(final_hc3.summary())
```

```

                                OLS Regression Results
=====
Dep. Variable:                Addicted_Score    R-squared:                0.945
Model:                        OLS              Adj. R-squared:           0.944
Method:                      Least Squares     F-statistic:             3530.
Date:                        Thu, 10 Sep 2026   Prob (F-statistic):       0.00
Time:                        16:04:59          Log-Likelihood:          -306.20
No. Observations:            704              AIC:                     620.4
Df Residuals:                700              BIC:                     638.6
Df Model:                    3
Covariance Type:             HC3
=====
=====
                                coef      std err          z      P>|z|
-----
[0.025      0.975]
-----
Intercept                    10.2550      0.318      32.202      0.000
9.631      10.879
Sleep_Hours_Per_Night       -0.2192      0.018     -12.074      0.000
-0.255      -0.184
Mental_Health_Score         -0.6789      0.032     -21.382      0.000
-0.741      -0.617
Conflicts_Over_Social_Media  0.6724      0.038      17.480      0.000
0.597      0.748
=====
Omnibus:                    32.591    Durbin-Watson:           2.074
Prob(Omnibus):              0.000    Jarque-Bera (JB):        44.815
Skew:                      0.413    Prob(JB):                1.86e-10
Kurtosis:                   3.919    Cond. No.                195.
=====

```

Notes:

[1] Standard Errors are heteroscedasticity robust (HC3)

4.4.1 계수 해석

```
[16]: focal = ["Sleep_Hours_Per_Night", "Mental_Health_Score", Conflicts_Over_Social_Media"]
coef_tbl = pd.DataFrame({
    "coef": final_hc3.params,
```

```

    "HC3_se": final_hc3.bse,
    "z": final_hc3.tvalues,
    "p_value": final_hc3.pvalues,
    "ci_low": final_hc3.conf_int()[0],
    "ci_high": final_hc3.conf_int()[1],
})
coef_tbl["std_beta"] = standardized_betas("Addicted_Score", focal, df)
coef_tbl.round(4)

```

```

[16]:
           coef  HC3_se      z  p_value  ci_low  ci_high
std_beta
Intercept      10.2550  0.3185  32.2024      0.0  9.6308  10.8791
NaN
Sleep_Hours_Per_Night -0.2192  0.0182 -12.0743      0.0 -0.2548 -0.1836
-0.1557
Mental_Health_Score -0.6789  0.0318 -21.3816      0.0 -0.7412 -0.6167
-0.4723
Conflicts_Over_Social_Media 0.6724  0.0385  17.4795      0.0  0.5970  0.7478
0.4059

```

- Mental_Health_Score: **-0.68** (수면·갈등 통제 시, 정신건강 1점 상승당 중독 -0.68점) — H1 지지
- Conflicts_Over_Social_Media: **+0.67** — H2 지지
- Sleep_Hours_Per_Night: **-0.22** — H3 지지
- 표준화 계수 기준으로 $|정신건강|(\approx 0.47) > |갈등|(\approx 0.41) > |수면|(\approx 0.16)$ 순서이며, HC3 유의확률은 모두 $p < 1e-10$.

4.4.2 핵심 계수 안정성 — 범주형 통제변수 추가 시

주 모형의 세 계수가 (a) 수치형 전체 모형, (b) 범주형 포함 모형에서 어떻게 변하는지 확인한다.

```

[17]: stab = pd.DataFrame({
    "M_parsimonious (HC3)": final_hc3.params.reindex(focal),
    "M_full_numeric (HC3)": model1.params.reindex(focal),
    "M_with_categ (HC3)": model2.params.reindex(focal),
}).round(4)
stab

```

```

[17]:
           M_parsimonious (HC3)  M_full_numeric (HC3)
M_with_categ (HC3)
Sleep_Hours_Per_Night          -0.2192          -0.2098
-0.1033
Mental_Health_Score          -0.6789          -0.6743
-0.5671
Conflicts_Over_Social_Media      0.6724          0.6642
0.3550

```

정신 건강·수면 계수는 세 명세에서 부호·크기가 안정적이다. 갈등 계수는 범주형 모형에서 약 0.67 → 0.36으로 줄어드는데, 이는 이 합성 데이터에서 플랫폼(Instagram, Twitter 등)이 갈등·중독과

함께 움직이도록 생성되어 분산 일부를 흡수하기 때문이다. 부호와 유의성은 세 명세에서 모두 유지되므로 정성적 결론은 바뀌지 않으나, 갈등 계수의 정확한 크기는 어떤 통제변수를 넣느냐에 민감하다는 점은 명시해 둔다.

```
[18]: print("Conflicts_Over_Social_Media 계수의 p-value:")
print(pd.Series({
    "M_parsimonious": final_hc3.pvalues["Conflicts_Over_Social_Media"],
    "M_full_numeric": model1.pvalues["Conflicts_Over_Social_Media"],
    "M_with_categ": model2.pvalues["Conflicts_Over_Social_Media"],
}))
```

```
Conflicts_Over_Social_Media 계수의 p-value:
M_parsimonious      2.051659e-68
M_full_numeric      3.322960e-57
M_with_categ        1.613856e-16
dtype: float64
```

```
[19]: # ANOVA (Type II): 계수가 아니라 분산 분해 (설명을 명확히 분리)
anova_tbl = sm.stats.anova_lm(final_ols, typ=2)
print(anova_tbl.round(4))
print("\n※ 위 sum_sq 열은 '제공합'이며 회귀계수가 아님.")
```

	sum_sq	df	F	PR(>F)
Sleep_Hours_Per_Night	21.0147	1.0	149.5311	0.0
Mental_Health_Score	71.6856	1.0	510.0819	0.0
Conflicts_Over_Social_Media	57.4215	1.0	408.5851	0.0
Residual	98.3762	700.0	NaN	NaN

※ 위 sum_sq 열은 '제공합'이며 회귀계수가 아님.

4.5 Model Diagnostics

4.5.1 1. 잔차 그림

```
[20]: def resid_plot(model, data):
    resid = model.resid
    fitted = model.fittedvalues
    infl = model.get_influence()
    std_resid = infl.resid_studentized_internal
    cooks_d = infl.cooks_distance[0]

    fig, ax = plt.subplots(2, 2, figsize=(11, 8))
    qqplot(resid, line="45", fit=True, ax=ax[0, 0])
    ax[0, 0].set_title("Q-Q plot (normality)")

    ax[0, 1].scatter(fitted, resid, alpha=0.5, s=18)
    ax[0, 1].axhline(0, ls="--", color="k")
```

```

ax[0, 1].set(xlabel="Fitted", ylabel="Residual",
             title="Residuals vs Fitted (linearity / homoskedasticity)")


ax[1, 0].scatter(fitted, np.sqrt(np.abs(std_resid)), alpha=0.5, s=18)
ax[1, 0].set(xlabel="Fitted", ylabel="sqrt(|std resid|)",
             title="Scale-Location (homoskedasticity)")

ax[1, 1].stem(range(len(cooks_d)), cooks_d, markerfmt=",")
ax[1, 1].axhline(4 / len(data), ls="--", color="r", label="4/n")
ax[1, 1].set(xlabel="Observation", ylabel="Cook's D", title="Cook's D
             distance (influence)")

ax[1, 1].legend()
plt.tight_layout()
plt.show()

resid_plot(final_ols, df)

```



4.5.2 2. 형식 검정

그림 해석에만 의존하지 않고 정규성·등분산·함수형태를 형식 검정으로 확인한다.

```
[21]: jrb_stat, jrb_p, skew, kurt = jarque_bera(final_ols.resid)
bp = het_breuschpagan(final_ols.resid, final_ols.model.exog)
white = het_white(final_ols.resid, final_ols.model.exog)
reset = linear_reset(final_ols, power=3, test_type="fitted", use_f=True)

diag = pd.DataFrame({
    "test": ["Jarque-Bera (정규성)", "Breusch-Pagan (등분산)", "White (등분산)",
            "Ramsey RESET p3 (함수형태)", "Durbin-Watson (자기상관)"],
    "statistic": [jrb_stat, bp[0], white[0], float(reset.fvalue),
    ↪durbin_watson(final_ols.resid)],
    "p_value": [jrb_p, bp[1], white[1], float(reset.pvalue), np.nan],
}).round(4)
print(diag.to_string(index=False))
print(f"\n왜도={skew:.3f}, 첨도={kurt:.3f} (n={len(df)})")
```

	test	statistic	p_value
Jarque-Bera (정규성)		44.8148	0.0000
Breusch-Pagan (등분산)		12.4985	0.0059
White (등분산)		25.4243	0.0025
Ramsey RESET p3 (함수형태)		61.9476	0.0000
Durbin-Watson (자기상관)		2.0736	NaN

왜도=0.413, 첨도=3.919 (n=704)

- 정규성: Jarque-Bera 기각. 다만 왜도 ≈ 0.4 , 첨도 ≈ 3.9 로 편차가 경미하고, $n \approx 700$ 에서 중심 극한정리에 의해 계수 추정량의 표집분포는 근사적으로 정규다. 아래 로버스트 회귀·순서형 로지스틱과 비교해 추론이 안정적임을 확인한다.
- 등분산: Breusch-Pagan / White가 유의하면 이분산이 존재하므로, 위에서 이미 **HC3** 강건 표준오차를 기본으로 사용했다. (원 보고서는 등분산 검정 없이 그림만으로 “등분산 만족”이라 서술했고 비강건 SE를 썼다.)
- 함수형태: RESET 검정으로 누락된 비선형항 여부 점검.

4.5.3 3. 영향관측치 민감도 분석

Cook's D $4/n$ 초과 관측치를 제거하고 재적합하여 계수가 크게 바뀌는지 확인한다.

```
[22]: infl = final_ols.get_influence()
cooks_d = infl.cooks_distance[0]
thr = 4 / len(df)
high_idx = np.where(cooks_d > thr)[0]
print(f"Cook's D > 4/n 관측치 수: {len(high_idx)} ({len(high_idx)/len(df):.
↪1%})")

trimmed = df.drop(index=df.index[high_idx])
final_trim = smf.ols(final_formula, data=trimmed).fit(cov_type="HC3")

compare_infl = pd.DataFrame({
    "full_HC3": final_hc3.params,
```

```

        "trimmed_HC3": final_trim.params,
        "abs_change": (final_hc3.params - final_trim.params).abs(),
    }).round(4)
    compare_infl

```

Cook's D > 4/n 관측치 수: 45 (6.4%)

```

[22]:
           full_HC3  trimmed_HC3  abs_change
Intercept          10.2550         10.0027         0.2522
Sleep_Hours_Per_Night -0.2192         -0.2256         0.0063
Mental_Health_Score   -0.6789         -0.6550         0.0240
Conflicts_Over_Social_Media  0.6724         0.7250         0.0526

```

4/n 규칙은 매우 민감한 경험칙이라 다수 관측치가 걸리지만, 이들을 모두 제거해도 계수 부호와 대략적 크기는 유지된다 → 결론이 소수 관측치에 좌우되지 않는다.

4.5.4 4. 추정 방법에 대한 민감도: 로버스트 회귀 · 순서형 로지스틱

종속 변수가 유계 순서형이라는 점, 잔차가 비정규라는 점을 고려하여 세 가지 추정을 비교한다.

```

[23]: # (a) Huber 로버스트 회귀
rlm = sm.RLM.from_formula(final_formula, data=df, M=sm.robust.norms.HuberT()).
    ↪fit()

# (b) 순서형 로지스틱 회귀 (부호·유의성 비교용; 계수 스케일은 OLS와 직접
    ↪비교 불가)
ord_endog = df["Addicted_Score"].astype(int)
ord_exog = df[["Sleep_Hours_Per_Night", "Mental_Health_Score",
    ↪"Conflicts_Over_Social_Media"]]
ord_mod = OrderedModel(ord_endog, ord_exog, distr="logit").fit(method="bfgs",
    ↪disp=False)

summary_methods = pd.DataFrame({
    "OLS_HC3_coef": final_hc3.params,
    "OLS_HC3_p": final_hc3.pvalues,
    "RLM_coef": rlm.params,
    "RLM_p": rlm.pvalues,
}).round(4)
print(summary_methods)
print("\n순서형 로지스틱 (기울기 계수만):")
print(ord_mod.params[["Sleep_Hours_Per_Night", "Mental_Health_Score",
    ↪"Conflicts_Over_Social_Media"]].round(4))
print(ord_mod.pvalues[["Sleep_Hours_Per_Night", "Mental_Health_Score",
    ↪"Conflicts_Over_Social_Media"]].round(6))

```

	OLS_HC3_coef	OLS_HC3_p	RLM_coef	RLM_p
Intercept	10.2550	0.0	10.0487	0.0
Sleep_Hours_Per_Night	-0.2192	0.0	-0.2202	0.0
Mental_Health_Score	-0.6789	0.0	-0.6592	0.0

Conflicts_Over_Social_Media	0.6724	0.0	0.7011	0.0
-----------------------------	--------	-----	--------	-----

순서형 로지스틱 (기울기 계수만):

Sleep_Hours_Per_Night	-1.8284
Mental_Health_Score	-5.2058
Conflicts_Over_Social_Media	5.6918

dtype: float64

Sleep_Hours_Per_Night	0.0
Mental_Health_Score	0.0
Conflicts_Over_Social_Media	0.0

dtype: float64

세 방법 모두에서 부호가 동일하고(Mental_Health -, Conflicts +, Sleep -) 세 변수 모두 $p < 0.001$ 로 유의하다. OLS 근사가 이 데이터에서 정성적 결론을 왜곡하지 않음을 확인한다.

4.6 하위집단 분석

```
[24]: gmm_y = GaussianMixture(n_components=2, random_state=SEED, n_init=10)
grp = gmm_y.fit_predict(df[["Addicted_Score"]])
if df.loc[grp == 0, "Addicted_Score"].mean() > df.loc[grp == 1,
    ↪ "Addicted_Score"].mean():
    grp = 1 - grp
df["_gmm_y"] = grp
n0 = int((grp == 0).sum())
VAR = "Mental_Health_Score"

def split_ztest(mask0):
    m0 = smf.ols(final_formula, data=df.loc[mask0]).fit()
    m1 = smf.ols(final_formula, data=df.loc[~mask0]).fit()
    z = (m0.params[VAR] - m1.params[VAR]) / np.sqrt(m0.bse[VAR] ** 2 + m1.
    ↪ bse[VAR] ** 2)
    p = 2 * (1 - stats.norm.cdf(abs(z)))
    return (df.loc[mask0, "Addicted_Score"].var(), df.loc[~mask0,
    ↪ "Addicted_Score"].var(),
            m0.params[VAR], m1.params[VAR], z, p)

gmm_res = split_ztest((df["_gmm_y"] == 0).to_numpy())

rand_p, rand_absdiff = [], []
for _ in range(200):
    m = np.zeros(len(df), dtype=bool)
    m[rng.permutation(len(df))[:n0]] = True
    r = split_ztest(m)
    rand_p.append(r[5])
    rand_absdiff.append(abs(r[2] - r[3]))
```

```
print(f"[GMM(Y) 분할] Var(Y): {gmm_res[0]:.2f} / {gmm_res[1]:.2f} "
      f"beta({VAR}): {gmm_res[2]:.3f} / {gmm_res[3]:.3f} z={gmm_res[4]:.2f} "
      f"p={gmm_res[5]:.2e}")
print(f"[무작위 분할 200회] 전체 Var(Y)={df['Addicted_Score'].var():.2f} "
      f"평균 |beta 차|={np.mean(rand_absdiff):.3f} "
      f"계수차가 p<.05로 유의한 비율={np.mean(np.array(rand_p) < 0.05):.1%}")
```

[GMM(Y) 분할] Var(Y): 0.41 / 0.74 beta(Mental_Health_Score): -0.768 / -0.533
 z=-4.22 p=2.48e-05
 [무작위 분할 200회] 전체 Var(Y)=2.52 평균 |beta 차|=0.058 계수차가 p<.05로
 ↳유의한 비율=5.0%

결과 해석

- **GMM(Y) 분할:** 두 그룹의 Var(Addicted_Score)가 전체(≈ 2.5)에서 $\approx 0.4 / \approx 0.7$ 로 급감하고, 정신건강 계수 차이가 원 보고서처럼 “유의”(p < 0.05)하게 나온다.
- **무작위 분할 200회:** 각 조각의 Y 분산은 전체와 같고, 계수 차이가 p < 0.05로 유의한 비율은 약 5%(우연 수준)에 그친다.

4.6.1 정정 1 — 상호작용(조절효과) 모형

하위표본을 나눠 계수를 사후 비교하는 대신, 전체 표본에 하나의 모형을 적합하고 그룹 × 예측 변수 상호작용항의 유의성을 검정한다(Chow/Wald 검정). 그룹은 종속 변수가 아니라 개념적으로 구분되는 변수(Affects_Academic_Performance: SNS가 학업에 영향을 준다고 인식하는지)로 설정한다. 상호작용 유의확률은 Benjamini-Hochberg로 다중비교 보정한다.

```
[25]: inter_formula = ("Addicted_Score ~ C(Affects_Academic_Performance) * "
                      "(Sleep_Hours_Per_Night + Mental_Health_Score + "
                      "↳Conflicts_Over_Social_Media)")
inter = smf.ols(inter_formula, data=df).fit(cov_type="HC3")
print(inter.summary())
```

```

                                OLS Regression Results
=====
Dep. Variable:                Addicted_Score    R-squared:                0.956
Model:                            OLS          Adj. R-squared:        0.956
Method:                    Least Squares      F-statistic:              2118.
Date:                Thu, 10 Sep 2026        Prob (F-statistic):        0.00
Time:                        16:05:02         Log-Likelihood:           -223.62
No. Observations:                704          AIC:                  463.2
Df Residuals:                    696          BIC:                  499.7
Df Model:                        7
Covariance Type:                HC3
=====
=====
                                coef
std err      z      P>|z|      [0.025      0.975]
-----
-----
-----
```

Intercept					11.2389
0.411	27.350	0.000	10.433	12.044	
C(Affects_Academic_Performance)[T.Yes]					-1.1142
0.604	-1.846	0.065	-2.297	0.069	
Sleep_Hours_Per_Night					-0.1808
0.042	-4.325	0.000	-0.263	-0.099	
C(Affects_Academic_Performance)[T.Yes]:Sleep_Hours_Per_Night					-0.0438
0.047	-0.937	0.349	-0.135	0.048	
Mental_Health_Score					-0.8457
0.063	-13.466	0.000	-0.969	-0.723	
C(Affects_Academic_Performance)[T.Yes]:Mental_Health_Score					0.3106
0.072	4.317	0.000	0.170	0.452	
Conflicts_Over_Social_Media					0.5884
0.066	8.876	0.000	0.458	0.718	
C(Affects_Academic_Performance)[T.Yes]:Conflicts_Over_Social_Media					-0.0836
0.089	-0.937	0.349	-0.258	0.091	
=====					
Omnibus:	71.259	Durbin-Watson:	2.093		
Prob(Omnibus):	0.000	Jarque-Bera (JB):	139.868		
Skew:	0.619	Prob(JB):	4.25e-31		
Kurtosis:	4.798	Cond. No.	578.		
=====					

Notes:

[1] Standard Errors are heteroscedasticity robust (HC3)

```
[26]: inter_terms = [p for p in inter.params.index if ":" in p]
inter_p = inter.pvalues[inter_terms]
inter_out = pd.DataFrame({
    "term": inter_terms,
    "coef": inter.params[inter_terms].values,
    "HC3_p": inter_p.values,
    "BH_p": bh_adjust(inter_p.values),
}).round(4)
print(inter_out.to_string(index=False))
```

	term	coef
HC3_p BH_p		
	C(Affects_Academic_Performance)[T.Yes]:Sleep_Hours_Per_Night	-0.0438
0.3487	0.3487	
	C(Affects_Academic_Performance)[T.Yes]:Mental_Health_Score	0.3106
0.0000	0.0000	
	C(Affects_Academic_Performance)[T.Yes]:Conflicts_Over_Social_Media	-0.0836
0.3485	0.3487	

```
[27]: # 그룹 전체 상호작용에 대한 결합(omnibus) Wald 검정
joint = inter.wald_test(inter_terms, scalar=True)
```

```
print(f"상호작용 결합 Wald 검정: F ≈ {float(joint.statistic):.3f}, p ≈ {float(joint.pvalue):.3e}, df={joint.df_denom:.0f}")
```

상호작용 결합 Wald 검정: F ≈ 48.912, p ≈ 1.362e-10, df=3

상호작용 항의 결합 검정으로 “연관의 크기가 하위집단에 따라 다른가”(H5)를 판단한다. 개별 상호작용은 BH 보정 후 유의확률로 해석한다. (합성 데이터에서 이 상호작용 역시 생성 규칙을 반영할 뿐이라는 점은 한계 절에서 다시 밝힌다.)

4.6.2 정정 2 — 설명변수 기반 잠재프로파일 (비지도 하위집단)

굳이 비지도 군집을 쓰려면, 종속 변수를 제외한 표준화된 설명변수로 군집해야 한다. 이렇게 얻은 프로파일은 Y로 정의되지 않으므로, 프로파일별 평균 Addicted_Score를 비교하는 것은 순환이 아니다. 군집 수 k는 BIC로 선택하고 분리도(entropy)를 함께 보고한다.

주의: 이 데이터의 “수치형” 설명변수도 실제로는 소수의 이산값만 취하므로(정신건강 6수준, 갈등 6수준 등), GMM의 BIC가 k를 늘릴수록 계속 감소한다. 따라서 해석 가능성을 위해 $k \leq 4$ 로 제한하고 그 범위에서 BIC 최소를 택한다.

```
[28]: prof_vars = ["Avg_Daily_Usage_Hours", "Sleep_Hours_Per_Night",
    ↪ "Mental_Health_Score",
    ↪ "Conflicts_Over_Social_Media", "Age"]
Z = StandardScaler().fit_transform(df[prof_vars])
K_MAX = 4

lpa_rows = []
best = None
for k in range(1, 7):
    gm = GaussianMixture(n_components=k, covariance_type="full",
    ↪ random_state=SEED, n_init=10)
    gm.fit(Z)
    bic = gm.bic(Z)
    if k == 1:
        ent = 0.0
    else:
        pp = gm.predict_proba(Z)
        ent = 1 - (-(pp * np.log(pp + 1e-12)).sum()) / (len(Z) * np.log(k))
    lpa_rows.append({"k": k, "BIC": bic, "entropy": ent})
    if k <= K_MAX and (best is None or bic < best[1]):
        best = (k, bic, gm)
lpa_cmp = pd.DataFrame(lpa_rows).round(2)
print(lpa_cmp.to_string(index=False))
print(f"\nk <= {K_MAX} 범위에서 BIC 최소 k = {best[0]}")
```

k	BIC	entropy
1	7435.95	0.00
2	7223.10	0.78
3	4064.84	1.00
4	-769.11	0.94

```
5 -1624.07      0.94
6 -2830.46      1.00
```

k <= 4 범위에서 BIC 최소 k = 4

```
[29]: best_k, _, best_gm = best
df["_profile"] = best_gm.predict(Z)

prof_summary = df.groupby("_profile").agg(
    n=("Addicted_Score", "size"),
    mean_Addicted=("Addicted_Score", "mean"),
    mean_Usage=("Avg_Daily_Usage_Hours", "mean"),
    mean_Sleep=("Sleep_Hours_Per_Night", "mean"),
    mean_Mental=("Mental_Health_Score", "mean"),
    mean_Conflict=("Conflicts_Over_Social_Media", "mean"),
).round(2)
print(prof_summary)

# 프로파일 간 Addicted_Score 평균 차이 (기술적 ANOVA)
groups = [g["Addicted_Score"].to_numpy() for _, g in df.groupby("_profile")]
f_stat, f_p = stats.f_oneway(*groups)
print(f"\n프로파일 간 Addicted_Score 평균차 ANOVA: F={f_stat:.2f}, p={f_p:.3e}")
```

	n	mean_Addicted	mean_Usage	mean_Sleep	mean_Mental	mean_Conflict
_profile						
0	112	8.36	6.24	5.42	5.05	4.00
1	96	4.80	3.76	8.16	7.65	2.35
2	449	6.29	4.89	6.95	6.29	2.71
3	47	6.57	4.38	6.89	5.60	2.40

프로파일 간 Addicted_Score 평균차 ANOVA: F=145.12, p=4.047e-73

프로파일은 사용시간·수면·정신건강·갈등 프로필이 다른 하위 집단이며, 프로파일별 평균 중독 점수 차이는 이 데이터의 설명변수-종속변수 관계를 (순환 없이) 요약한다.

5 종합: 다중비교 보정

조절효과 분석에서 나온 상호작용 유의확률을 한데 모아 Benjamini-Hochberg FDR로 보정한 결과를 재확인한다(위 표의 BH_p). 주 모형의 3개 핵심 계수는 $p < 1e-10$ 수준으로 어떤 보정에도 유의성이 유지된다.

6 Limitations

1. **합성 데이터.** 자료는 Kaggle 공개 합성 데이터셋으로, 종속 변수가 설명 변수의 거의 결정론적 함수이며(704개 설명변수 조합이 모두 유일한 중독 점수에 대응), 상관·결정계수가 실제 행동과학 자료에서 관측되기 어려운 수준($R^2 \approx 0.95$)이다. 본 보고서의 모든 계수·유의성·하위집단 차이는 이 데이터셋의 생성 구조에 대한 기술이며, 실제 학생 모집단으로 일반화되지 않는다.
 2. **횡단면·관찰 자료.** 어떤 변수도 실험적으로 조작되지 않았으므로 인과 해석이 불가능하다. 역인과(중독 → 수면·정신건강 악화)와 미측정 교란이 모두 가능하다. 본문은 “연관/상관” 언어만 사용한다.
 3. **구 성 개 념 순 환.** `Conflicts_Over_Social_Media`, `Avg_Daily_Usage_Hours`, `Affects_Academic_Performance`는 중독 구성개념과 개념적으로 겹친다. 이들이 포함된 모형의 설명력은 부분적으로 동어반복이다.
 4. **측정.** `Addicted_Score`는 검증된 심리척도(예: BSMAS)가 아닌 2-9 점수 지표다. OLS는 유계 순서형 변수를 연속으로 근사하며(범위 밖 예측 가능), 본 보고서는 순서형 로지스틱·로버스트 회귀로 정성적 결론의 안정성만 확인했다.
 5. **표본추출.** 704명의 모집단·표집틀·응답률이 문서화되어 있지 않아 대표성을 평가할 수 없다.
 6. **Country.** 110개 수준 중 다수가 관측치 1-2개로 식별이 불안정하여 주 모형에서 제외했다. 국가 효과 분석에는 지역 집계 또는 혼합효과 모형이 필요하다.
-

7 Conclusion

7.1 요약 (이 데이터셋에 한정)

1. 정신 건강 점수는 수면·갈등을 통제한 뒤에도 중독 점수와 가장 강한 음의 연관을 보이며 (표준화 β 기준 최대), HC3 강건 SE·로버스트 회귀·순서형 로지스틱에서 모두 $p < 0.001$ 로 일관된다.
2. SNS 관련 갈등 경험은 중독 점수와 강한 양의 연관을 보인다.
3. 수면 시간은 중독 점수와 음의 연관을 보이거나 효과 크기는 위 둘보다 작다.
4. 일일 사용 시간과 나이는 단순 상관은 있으나 다른 변수 통제 시 부분효과가 유의하지 않다 (H4 미지지). 성별·학업 수준·플랫폼·관계상태의 추가 설명력은 미미하다.
5. 하위집단에 따른 연관 크기의 차이 (H5)는 상호작용 모형으로 검정해야 하며, 원 보고서처럼 종속 변수로 군집을 만들어 하위표본 회귀를 비교하면 범위 축소에 의한 인공적 계수 차이가 발생한다.

7.2 방법론적 시사점

- 하위집단/조절효과는 하나의 모형 + 상호작용항(Chow 검정)으로 다루고, 비지도 군집이 필요하면 종속 변수를 제외한 설명변수로 군집한다.
- 이분산 검정을 형식적으로 수행하고 강건(HC3) 표준오차를 기본값으로 삼는다.
- 유계 순서형 종속 변수에는 순서형 로지스틱을 민감도 분석으로 병행한다.
- “가장 영향력 있는 요인”은 표준화 계수로 비교하고, 다수의 검정에는 FDR 보정을 적용한다.
- 변수 제거 근거(비유의 vs 다중공선성)를 구분해 명시하고, 모형 선택은 AIC/BIC·교차검증으로 정당화한다.